

Uzak Sunucudaki Modeli LiteLLM'e Bağlama

vLLM ile bir modeli başka bir makinede API olarak sunma ve LiteLLM proxy'nize bağlama — adım adım. Senaryo: diğer sunucuda hiçbir şey kurulu değil, sadece model dosyaları var ve yerelde çalıştırılabilir durumda.

BÖLÜM A — MODELİN BULUNDUĞU (UZAK) SUNUCUDA

1. Docker'ı kurun ve doğru vLLM image'ını seçin

Sunucuda sadece Docker olması yeterli (pip install gerekmiyor). Docker kuruluysa (curl -fsSL https://get.docker.com | sh ile tek satırda kurulabilir), doğru resmi vLLM image'ını seçin:

Donanım	Image
GPU (NVIDIA, CUDA)	vllm/vllm-openai:latest
CPU-only (GPU yok)	vllm/vllm-openai-cpu:latest-x86_64

```
# GPU sunucu:
docker pull vllm/vllm-openai:latest

# CPU-only sunucu:
docker pull vllm/vllm-openai-cpu:latest-x86_64
```

NOT: Sunucuda GPU olup olmadığını bilmiyorsanız 'nvidia-smi' komutunu deneyin -- çalışıp bir GPU listeliyorsa GPU image'ı, 'command not found' veya hata veriyorsa CPU image'ı kullanın.

2. Bir API key üretin

vLLM sunucunuzu korumasız bırakmayın — kimin erişebileceğini siz belirleyeceğiniz bir anahtar üretin (bu anahtarı 4. adımda hem test için, hem de LiteLLM tarafında kullanacaksınız).

```
python3 -c "import secrets; print(secrets.token_urlsafe(32))"
# örnek çıktı: sk-remote-8f2c1a9b4d7e6f3a...
```

3. vLLM konteynerini docker run ile başlatın

Model dosyalarınızın bulunduğu klasörü konteynere salt-okunur bağlayın (-v), portu dışarı açın (-p 8000:8000) ve API key koyun. --served-model-name, LiteLLM'e gireceğiniz isimle birebir aynı olmalı.

GPU sunucu:

```
docker run -d --name my-vllm-server \
  --gpus all \
  -p 8000:8000 \
  -v /path/to/model:/models/my-model:ro \
  vllm/vllm-openai:latest \
  /models/my-model \
  --served-model-name my-remote-model \
  --api-key sk-remote-8f2c1a9b4d7e6f3a \
  --host 0.0.0.0
```

CPU-only sunucu:

```
docker run -d --name my-vllm-server \
  --shm-size=1g \
  -p 8000:8000 \
  -v /path/to/model:/models/my-model:ro \
  vllm/vllm-openai-cpu:latest-x86_64 \
  /models/my-model \
  --served-model-name my-remote-model \
  --api-key sk-remote-8f2c1a9b4d7e6f3a \
  --host 0.0.0.0 \
  --gpu-memory-utilization 0.3
```

CPU'da `--gpu-memory-utilization` ismine rağmen GPU değil, sunucunun RAM'inin ne kadarının modele ayrılacağını belirler (örn. 0.3 = RAM'in %30'u) -- modelin boyutuna göre ayarlayın.

Durumu izlemek için (model yüklenirken birkaç dakika sürebilir):

```
docker logs -f my-vllm-server

# Beklenen çıktı (en alt satırları) -- bunları görünce sunucu hazırdır:
# INFO:      Started server process [1]
# INFO:      Waiting for application startup.
# INFO:      Application startup complete.
# INFO:      Uvicorn running on http://0.0.0.0:8000
```

NOT: `-p 8000:8000` olmadan konteyner dışarıdan erişilemez olur; LiteLLM sunucunuz asla ulaşamaz. `--host 0.0.0.0` varsayılan olsa da açıkça belirtmek daha güvenlidir.

3b. Bu sunucunun IP adresini öğrenin

API Base'e (7. adımda) yazacağınız IP budur. Aynı özel ağdaysanız (VPC/ofis/ev ağı) local IP yeterli; LiteLLM başka bir ağdaysa bulut sağlayıcınızın konsolundaki **public IP**'yi kullanmanız gerekir.

```
hostname -I
# örnek çıktı: 10.0.1.15 172.17.0.1

# ya da:
ip addr show | grep 'inet '
# örnek çıktı:
#   inet 127.0.0.1/8 scope host lo
#   inet 10.0.1.15/24 brd 10.0.1.255 scope global eth0
```

Bulut VM'iyse (AWS/GCP/Azure/DigitalOcean vb.) bu local IP'ler dışarıdan erişilemez — konsolda yazan **Public IPv4 address**'i kullanın.

4. Aynı sunucudan kendi kendine test edin

Sunucu ayağa kalktıktan sonra, hâlâ o makinedeyken önce kendi kendine bir istek atıp API key'in ve modelin doğru çalıştığını doğrulayın.

```
curl http://localhost:8000/v1/models \
  -H "Authorization: Bearer sk-remote-8f2c1a9b4d7e6f3a"

# Beklenen çıktı:
# {"object": "list", "data": [{"id": "my-remote-model", "object": "model", ...}]}
```

5. Güvenlik duvarında/portta 8000'i açın

Bulutta bir VM ise, sağlayıcının Security Group / Firewall ayarından 8000 portunu (mümkünse sadece LiteLLM sunucunuzun IP'sine) açın. Kendi sunucunuzdaysanız ufw/iptables ile aynısını yapın.

```
sudo ufw allow 8000/tcp    # ornek (Ubuntu)
# Bulut saglayicisinda: Security Group -> Inbound Rules -> TCP 8000 ekleyin
```

BÖLÜM B — SİZİN LiteLLM SUNUCUNUZDA

6. Uzak sunucuya buradan ulaşabildiğinizi doğrulayın

LiteLLM proxy'nizin çalıştığı makineden, uzak sunucunun IP'sine ve portuna aynı curl testini tekrarlayın. Bu adım başarısız olursa 7. adımda LiteLLM de bağlanamaz — firewall/routing sorununu önce burada çözün.

```
curl http://203.0.113.25:8000/v1/models \
-H "Authorization: Bearer sk-remote-8f2c1a9b4d7e6f3a"
# (203.0.113.25 yerine uzak sunucunun gercek IP/hostname'ini yazin)

# BASARILI ise:
# {"object": "list", "data": [{"id": "my-remote-model", "object": "model", ...}]}

# BASARISIZ ise (port kapali / firewall):
# curl: (7) Failed to connect to 203.0.113.25 port 8000: Connection refused
# ya da hicbir cikti vermeden uzun sure bekletir (timeout)
# -> 5. adima donup portu/firewall'i kontrol edin
```

API Base olarak 7. adıma gireceğiniz değer, bu komuttaki URL'in /models kısmı olmadan hâlidir — yani http://203.0.113.25:8000/v1.

7. LiteLLM Admin UI -> Models + Endpoints -> Add Model

Sol menüden **Models + Endpoints**, üstteki sekmelerden **Add Model**'e girin. Aşağıdaki alanları doldurun (gerçek LiteLLM Admin UI'deki alan sırasıyla birebir aynı):

[Add Model]

Provider	vllm
LiteLLM Model Name(s)	my-remote-model
API Base	http://203.0.113.25:8000/v1
API Key	sk-remote-8f2c1a9b4d7e6f3a

Add Model

API Base mutlaka /v1 ile bitmeli. **API Key** alanına 2. adımda ürettiğiniz anahtarını aynen yapıştırın. Önce **Test Connect** ile bağlantıyı doğrulayıp sonra **Add Model**'e tıklamanız önerilir.

8. Bağlantıyı doğrulayın

Model listede görüldükten sonra Playground'dan (veya kendi test scriptinizden) modele bir mesaj gönderip gerçek bir yanıt aldığınızı kontrol edin.

[Playground]

Model	my-remote-model
Mesaj	Merhaba, çalışıyor musun?
Yanıt	Evet, buradayım — nasıl yardımcı olabilirim?

9. (Opsiyonel) config.yaml ile aynısı

Admin UI yerine dosya-tabanlı yapılandırmayı tercih ediyorsanız, config.yaml'a aşağıdaki bloğu ekleyip proxy'yi yeniden başlatmanız yeterli:

```
model_list:
- model_name: my-remote-model
  litellm_params:
    model: hosted_vllm/my-remote-model
    api_base: http://203.0.113.25:8000/v1
    api_key: sk-remote-8f2c1a9b4d7e6f3a
```

Sık Karşılaşılan Sorunlar

Belirti	Muhtemel sebep
Connection refused / timeout	--host 0.0.0.0 unutuldu ya da firewall/security group portu kapalı
401 Unauthorized	API key yanlış kopyalandı, ya da Authorization header'da 'Bearer ' öneki eksik
Model bulunamadı / 404	--served-model-name ile LiteLLM'e girilen isim birebir aynı değil
LiteLLM'den yavaş/timeout yanıt	Uzak sunucu CPU'da çalışıyor olabilir — model boyutuna göre normal; --gpu-memory-utilization ile ayarlanabilir